SEMEVAL-2026 // TASK 13

GenAI Code Detection & Attribution

Speech & Language Processing Exam

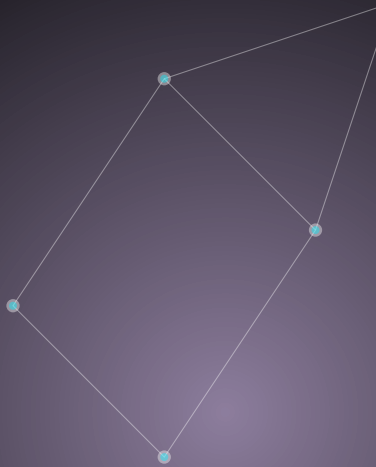

Giovanni Giuseppe Iacuzzo

Università degli Studi di Enna “Kore”

AI & Cybersecurity Student · giovannilacuzzo

Roadmap

1. Introduzione e Obiettivi
2. Architecture dei modelli
3. Analisi dei Dati
4. Risultati del Task
5. Conclusioni

Il Nuovo Paradigma: GenAI Code

⚠ The Rise of LLMs

L'evoluzione di modelli come **GPT-4, Llama-3 e StarCoder** ha reso il codice sintetico indistinguibile da quello umano. Questo fenomeno introduce rischi critici per la **sicurezza software**, il **copyright** e l'integrità dei sistemi.

Human Code

(Creativity, Bugs)

GenAI Code

(Speed, Patterns)

Il Nuovo Paradigma: GenAI Code

⚠ The Rise of LLMs

L'evoluzione di modelli come **GPT-4, Llama-3 e StarCoder** ha reso il codice sintetico indistinguibile da quello umano. Questo fenomeno introduce rischi critici per la **sicurezza software**, il **copyright** e l'integrità dei sistemi.

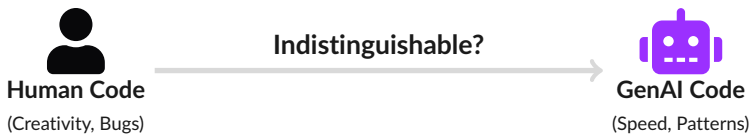

Il Nuovo Paradigma: GenAI Code

⚠ The Rise of LLMs

L'evoluzione di modelli come **GPT-4, Llama-3 e StarCoder** ha reso il codice sintetico indistinguibile da quello umano. Questo fenomeno introduce rischi critici per la **sicurezza software**, il **copyright** e l'integrità dei sistemi.

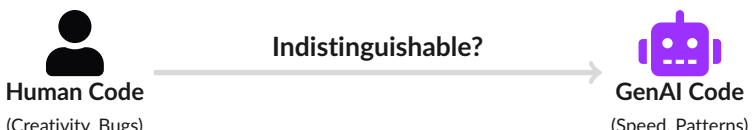

Obiettivi della Competizione

La Task 13 risponde a tre esigenze fondamentali dell’industria moderna:

Sicurezza

Prevenire vulnerabilità introdotte da codice generato (Hallucinations) in sistemi critici.

Obiettivi della Competizione

La Task 13 risponde a tre esigenze fondamentali dell'industria moderna:

Sicurezza

Prevenire vulnerabilità introdotte da codice generato (Hallucinations) in sistemi critici.

Attribuzione

Identificare il modello specifico (es. Llama vs OpenAI) per licensing e proprietà intellettuale.

Obiettivi della Competizione

La Task 13 risponde a tre esigenze fondamentali dell'industria moderna:

Sicurezza

Prevenire vulnerabilità introdotte da codice generato (Hallucinations) in sistemi critici.

Attribuzione

Identificare il modello specifico (es. Llama vs OpenAI) per licensing e proprietà intellettuale.

Analisi Ibrida

Gestire scenari complessi: codice misto Uomo-AI, Refactoring e Codice Avversario.

Struttura del Progetto: I 3 Moduli

Una pipeline unificata per affrontare i tre livelli di complessità del task:

Subtask A · Binary Detection

Human vs Machine.
Classificazione binaria su 500K sample. Include scenari *Unseen Languages* (es. Go, PHP) e *Unseen Domains*.

Struttura del Progetto: I 3 Moduli

Una pipeline unificata per affrontare i tre livelli di complessità del task:

Subtask A · Binary Detection

Human vs Machine.
Classificazione binaria su 500K sample. Include scenari *Unseen Languages* (es. Go, PHP) e *Unseen Domains*.

Subtask B · Attribution

Multi-Class (11 Families).
Identificazione fine-grained dell'autore (Human, GPT, Llama, Mistral, ecc.). Sfida: Forti sbilanciamenti di classe.

Struttura del Progetto: I 3 Moduli

Una pipeline unificata per affrontare i tre livelli di complessità del task:

Subtask A · Binary Detection

Human vs Machine.
Classificazione binaria su 500K sample. Include scenari *Unseen Languages* (es. Go, PHP) e *Unseen Domains*.

Subtask B · Attribution

Multi-Class (11 Families).
Identificazione fine-grained dell'autore (Human, GPT, Llama, Mistral, ecc.). Sfida: Forti sbilanciamenti di classe.

Subtask C · Hybrid Analysis

Mixed & Adversarial (4 Classi).
Classificazione complessa: Human, Machine, Hybrid (Mixed) e Adversarial (Codice offuscato). 900K sample.

Subtask A: Hybrid Forensics Pipeline

L'architettura proposta combina la potenza degli LLM con tecniche di analisi forense classica tramite una strategia di **Late Fusion**.

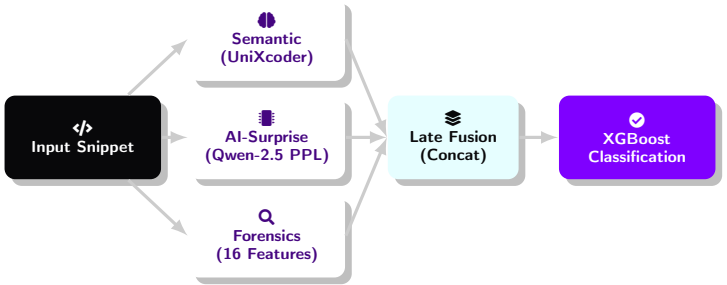

Rationale: Gli LLM lasciano tracce statistiche ("Surprise") e stilistiche (Forensics) diverse, che i modelli semantici puri (UniXcoder) potrebbero ignorare.

1. AI-Surprise & Stylometric Forensics

Perplexity Engine

Utilizziamo **Qwen2.5-Coder-1.5B** per calcolare quanto il modello è "sorpreso" dal codice.

- **Ipotesi:** Il codice generato da AI ha una Perplexity (PPL) inferiore rispetto a quello umano.
- **Implementazione:**
  - Sliding Window Processing.
  - OOM Auto-Recovery (Dynamic Batching).
  - Feature: `cross_entropy_loss`.

Forensic Features (16 dim)

Estrazione di pattern stilistici tramite Regex:

- **Entropy & TTR:** Complessità lessicale.
- **Naming Inconsistency:** Mix di `snake_case` e `camelCase` (tipico umano).
- **Layout:** Spazi bianchi e indentazione.
- **Identifiers:** Entropia nomi variabili.

2. Semantic Backbone & Late Fusion

Semantic Encoding (Microsoft UniXcoder)

Per catturare la logica del codice, utilizziamo **UniXcoder-base**.

- **Processo:** Input (512 token) $\rightarrow$ Forward Pass $\rightarrow$ Mean Pooling.
- **Output:** Vettore denso a **768 dimensioni**.

Late Fusion & XGBoost

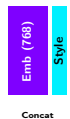

Le feature vengono concatenate in un unico vettore **[784 dim]**:

$$V_{final} = \text{Concat}(\mathbf{E}_{sem}, \mathbf{F}_{style}, \mathbf{P}_{ppl})$$

Perché XGBoost?

- Gestisce bene dati eterogenei (Dense + Sparse).
- **Feature Importance:** Conferma che *Perplexity* e *Entropy* sono discriminatori chiave.
- Training con **Early Stopping**.

Subtask B: The Attribution Challenge

A differenza del task binario, qui l'obiettivo è identificare l'**esatta famiglia** del modello (Fine-Grained Classification) in uno scenario fortemente sbilanciato.

11 Target Classes

Il modello deve distinguere tra:

- **1 Classe Umana** (Dominante).
- **10 Famiglie AI:** GPT-4, Llama-3, StarCoder, Mistral, Qwen, DeepSeek, ecc.

Key Challenges:

- **Extreme Imbalance:** Human »> AI (442k vs 2k-10k).
- **OOD Detection:** Gestire modelli "Unseen" nel test set.

Data Distribution

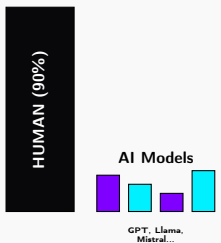

Approccio diretto → Bias verso "Human".
*Soluzione: **Cascade Inference**.*

Strategy: Cascade Inference Pipeline

Per mitigare i falsi positivi sulla classe maggioritaria (Human), abbiamo diviso il problema in due stadi logici sequenziali.

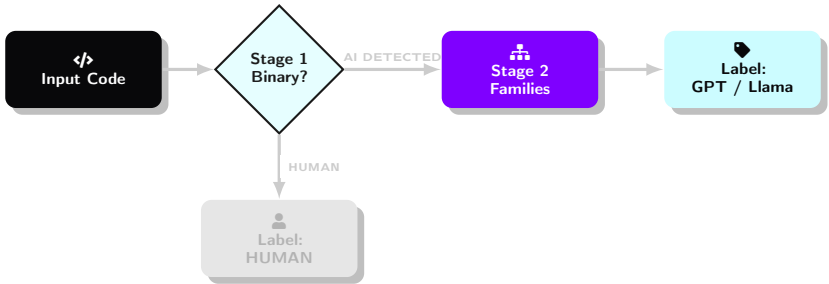

Stage 1 (Binary Filter)
Protegge dai falsi positivi umani.

Stage 2 (Fine-Grained)
Specializzato solo sulle differenze tra LLM.

Architecture: Style-Injected Neural Network

Custom Model Architecture

Estensione di **UniXcoder-base** con iniezione di feature stilistiche nello spazio latente.

- **Attention Pooling:** Somma pesata dei token (meglio del [CLS] standard).
- **Style Projector:** 8 feature manuali (es. density, snake_case) proiettate in uno spazio denso.
- **Feature Fusion:** Concatenazione (Semantic + Projected Style) pre-classifica.

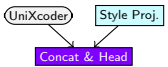

Advanced Training Strategy

- **Supervised Contrastive Loss (SupCon):** Avvicina nello spazio vettoriale gli snippet della stessa famiglia (es. Llama-2 e Llama-3) e allontana famiglie diverse.
- **Focal Loss:** Penalizza gli errori sulle classi difficili/rare, mitigando l'impatto dello sbilanciamento delle classi.

Subtask C: Hybrid & Adversarial Code

Il livello più avanzato della competizione: rilevare non solo chi ha scritto il codice, ma **come** è stato modificato o offuscato.

4 Target Classes

Il modello deve classificare lo snippet in:

- **0: Human-Written**
- **1: Machine-Generated**
- **2: Hybrid (Mixed):** Codice umano completato o refactorizzato da AI.
- **3: Adversarial:** Codice AI generato con prompt avversari per evadere la detection.

Robustness Goal

Problem: I modelli standard imparano correlazioni spurie (es. "C++ è sempre umano").

Solution: Dobbiamo costringere il modello a ignorare il linguaggio e guardare la *struttura*.

Key Tech: ***Domain Adversarial Training (DANN)***

Architecture: Language-Invariant Learning

Per generalizzare su linguaggi non visti (es. Go, PHP), utilizziamo un **Gradient Reversal Layer (GRL)**.

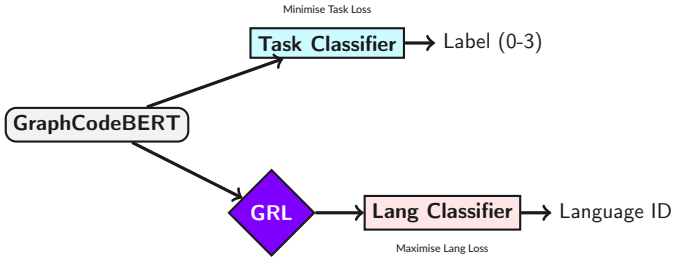

Logic: Il GRL inverte il gradiente durante la backpropagation. Il modello impara feature che sono *utili per la classificazione* ma *inutili per indovinare il linguaggio*, diventando così "Language Agnostic".

Training Strategy & Ensemble Submission

Multi-Objective Loss Function

$$\mathcal{L}_{total} = \mathcal{L}_{Task} + \lambda_1 \mathcal{L}_{SupCon} + \lambda_2 \mathcal{L}_{DANN}$$

- **Focal Loss ($\mathcal{L}_{Task}$):** Gestisce lo sbilanciamento delle 4 classi.
- **SupCon ($\mathcal{L}_{SupCon}$):** Clusterizza feature simili (es. Hybrid con Hybrid).
- **Adversarial ($\mathcal{L}_{DANN}$):** Rimuove il bias del linguaggio.

5-Fold Ensemble Inference

Per la sottomissione finale, non usiamo un singolo modello ma un **Ensemble di 5 modelli** addestrati su fold diversi (Cross-Validation).

- **Aggregazione:** Soft Voting (Media delle probabilità).
- **Beneficio:** Riduce la varianza e aumenta la robustezza su dati OOD.

Task A [Train]: Learning Source Bias

Analisi del Training Set (500k sample). Notiamo un forte bias verso linguaggi popolari e generatori specifici.

Languages

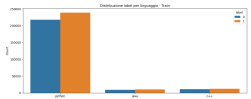

Dominio: Python/Java.

Length

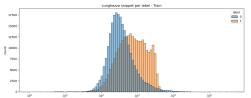

AI è più verbosa (Code Llama).

Generators

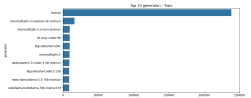

GPT-4 e Llama dominanti.

Insight: Il modello rischia di sovra-adattarsi allo stile di GPT-4 se non regolarizzato.

Task A [Validation]: Consistency Check

Verifica che il Validation Set rispecchi la distribuzione del Train per evitare il "Data Leakage" o shift distribuzionali.

Label Consistency

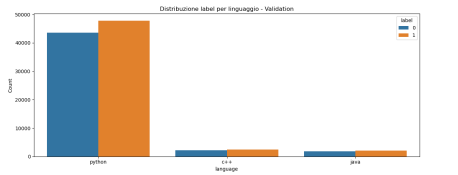

Validation Generators

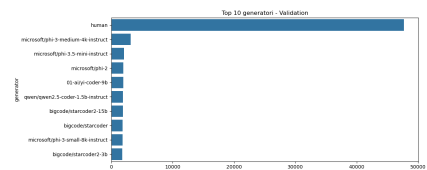

Task A [Test]: The "Unseen" Challenge

Il Test Set introduce la vera difficoltà: linguaggi e generatori **MAI VISTI** durante il training.

⚠ OOD Languages

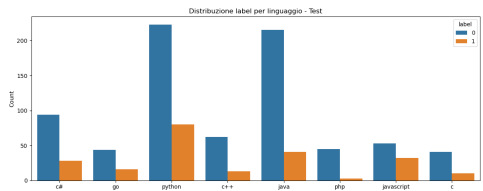

Impact Analysis

Il grafico mostra la comparsa di:

- **Go, PHP, C#**: Assenti nel train.
- **Obiettivo:** Valutare se il modello ha imparato la "struttura dell'AI" o solo la "sintassi di Python".

*Ecco perché usiamo feature agnostiche come la **Perplexity**.*

Task B [Train]: Fingerprinting Analysis

Analisi delle caratteristiche uniche dei modelli AI per l'attribuzione di paternità.

Extreme Imbalance

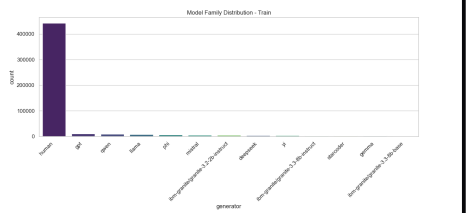

Human (90%) oscura le 10 classi AI.

Verbosity (Tokens)

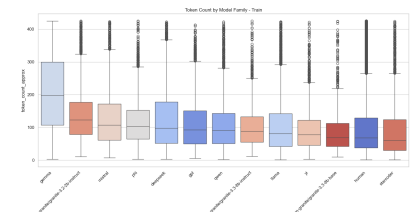

GPT-4 (verbose) vs Llama (conciso).

Strategy: Utilizzo di **Focal Loss** per le classi rare e feature di lunghezza per distinguere i modelli.

Task B [Validation]: Correlation Map

Analisi delle correlazioni condizionate: "Quale modello scrive in quale linguaggio?"

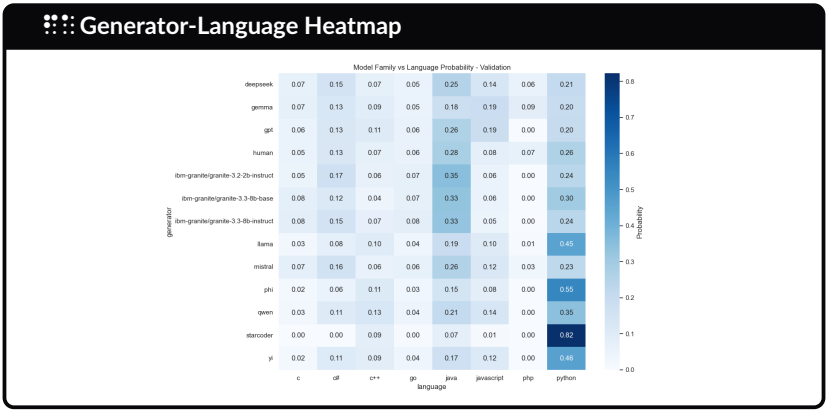

Alcuni modelli sono specializzati (es. StarCoder su Java), creando pattern riconoscibili.

Task B [Test]: Robustness Verification

Verifica finale sulla distribuzione dei token nel set di Test per confermare l’assenza di drift anomali.

Class Distribution (Test)

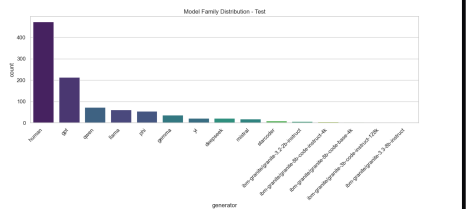

Token Distribution

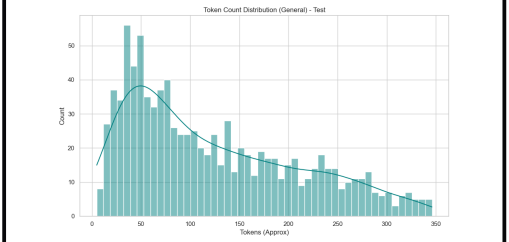

Task C [Train]: The 4-Class Problem

Analisi delle classi complesse: **Hybrid** (Uomo+AI) e **Adversarial** (Offuscato).

Target Distribution

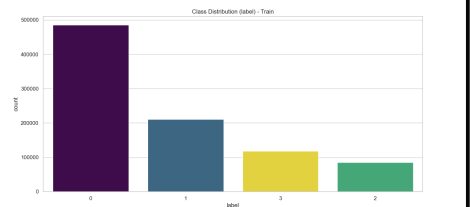

Hybrid e Adversarial sono minoritarie.

Language Variety

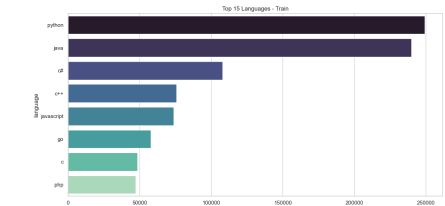

Elevata frammentazione linguistica.

Solution: *Structural Noise Injection* per aumentare i campioni rari.

Task C [Validation]: Length & Features

Controllo della distribuzione delle lunghezze per settare correttamente la *max_length* del Transformer (GraphCodeBERT).

Length Distribution (Val)

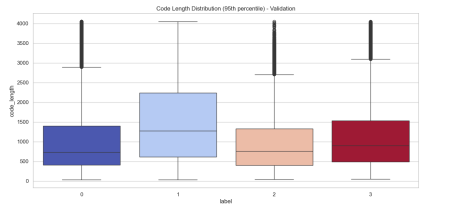

Target Check (Val)

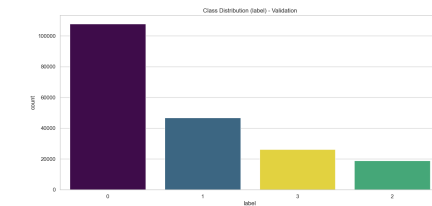

Task C [Test]: Preparing for Submission

Analisi finale sul Sample Test Set per garantire che la pipeline di inferenza gestisca correttamente i dati non visti.

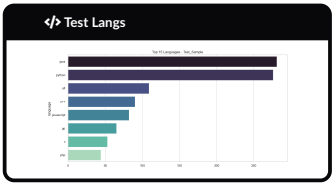

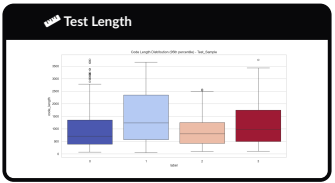

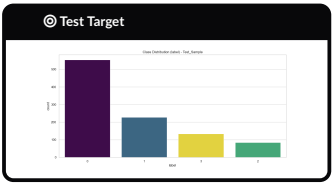

Grazie per l’attenzione

github.com/giovanniIacuzzo
giovanni.iacuzzo@unikore.it